

# Trabalho Computacional I

## 1 Problema 1

Imagine que você está controlando a temperatura de um forno industrial. O objetivo é que a temperatura atinja um valor de referência ( $T_{\text{ref}}$ ) e permaneça estável nesse ponto, independentemente de variações externas. Para isso, usamos um controlador PID que ajusta o sinal de controle  $u(t)$  com base no erro entre a temperatura atual  $T(t)$  e a temperatura de referência. O controlador PID é definido pela seguinte equação:

$$u(t) = K_p e(t) + K_i \int_0^t e(\tau) d\tau + K_d \frac{d}{dt} e(t) \quad (1)$$

onde:

- $e(t) = T_{\text{ref}} - T(t)$  é o erro entre a temperatura de referência e a temperatura atual.
- $K_p$ ,  $K_i$ , e  $K_d$  são os ganhos proporcional, integral e derivativo, respectivamente.
- $u(t)$  é o sinal de controle que será aplicado para ajustar o sistema (por exemplo, potência aplicada ao aquecedor).

O objetivo é ajustar os parâmetros  $K_p$ ,  $K_i$ , e  $K_d$  de forma a minimizar uma métrica de desempenho, como o tempo de estabilização, o erro quadrático médio (MSE), ou o tempo de resposta. Um dos critérios comuns é minimizar o erro quadrático médio ao longo de um período de tempo  $T_{\text{sim}}$ , que pode ser expresso como:

$$J(K_p, K_i, K_d) = \int_0^{T_{\text{sim}}} e(t)^2 dt \quad (2)$$

A função-objetivo para o problema de otimização seria minimizar o erro quadrático médio  $J(K_p, K_i, K_d)$ , o que pode ser formulado como:

$$\min_{K_p, K_i, K_d} \int_0^{T_{\text{sim}}} (T_{\text{ref}} - T(t, K_p, K_i, K_d))^2 dt \quad (3)$$

sendo que a temperatura  $T(t, K_p, K_i, K_d)$  é obtida a partir da solução de um modelo matemático que descreve a dinâmica do sistema. Para simplificar, considere que o modelo é dado por uma equação diferencial ordinária (EDO) de primeira ordem:

$$\frac{dT}{dt} = -\frac{T}{\tau} + \frac{K}{\tau} u(t) \quad (4)$$

onde  $\tau$  é a constante de tempo do sistema e  $K$  é uma constante de proporcionalidade. Portanto, o objetivo é encontrar os parâmetros  $K_p$ ,  $K_i$ , e  $K_d$  que minimizam o erro quadrático médio  $J(K_p, K_i, K_d)$  ao longo de um período de simulação  $T_{\text{sim}}$ .

Para resolver o problema, considere os seguintes parâmetros:

- $T_{\text{ref}} = 100^\circ\text{C}$  (temperatura de referência).
- $T(0) = 25^\circ\text{C}$  (temperatura inicial).
- $K_p = 1$ ,  $K_i = 0.1$ ,  $K_d = 0.01$  (valores iniciais dos ganhos).
- $\tau = 1$  (constante de tempo do sistema).
- $T_{\text{sim}} = 10$  segundos (tempo de simulação).
- $K = 1$  (constante de proporcionalidade).

Para resolver o problema, você pode aproveitar a implementação da função-objetivo disponível no arquivo `questao1.py`. Você vai ter que implementar a chamada do algoritmo de otimização. Escolha o algoritmo mais adequado para resolver o problema baseado em suas características, justifique a sua escolha e apresente os resultados da otimização.

## 2 Problema 2

A regressão logística é um modelo de classificação binária que estima a probabilidade de um evento ocorrer. Ela pode ser usada em diferentes aplicações, como diagnóstico médico, previsão de vendas, ou análise de risco. Por exemplo, suponha você tenha um conjunto de  $m$  músicas e cada música é descrita por um conjunto de  $n$  características (por exemplo, gênero, duração, popularidade, etc.). Para cada uma dessas músicas, você tem um rótulo binário indicando se a música foi um sucesso ou não. O objetivo é prever se uma música será um sucesso ou não com base nessas características.

De uma maneira básica, o modelo recebe um conjunto de dados  $(\mathbf{x}_i, y_i)$  onde:

- $\mathbf{x}_i \in \mathbb{R}^n$  é o vetor de entrada com cada uma das  $n$  características da  $i$ -ésima música.
- $y_i \in \{0, 1\}$  é o rótulo da  $i$ -ésima música, i.e., se ela foi um sucesso (1) ou não (0).

O modelo, ao receber esse conjunto de dados, determina um conjunto de pesos  $\mathbf{w} \in \mathbb{R}^n$  que melhor se ajusta aos dados. Determinar esses pesos é um problema de otimização, onde o objetivo pode ser definido como minimizar a função de custo de entropia cruzada regularizada:

$$J(\mathbf{w}) = -\frac{1}{m} \sum_{i=1}^m [y_i \log(h(\mathbf{x}_i; \mathbf{w})) + (1 - y_i) \log(1 - h(\mathbf{x}_i; \mathbf{w}))] + \frac{\lambda}{2} \|\mathbf{w}\|^2 \quad (5)$$

onde:

- $h(\mathbf{x}_i; \mathbf{w}) = \frac{1}{1+e^{-\mathbf{w}^\top \mathbf{x}_i}}$  é a saída do modelo logístico (função sigmoide).
- $m$  é o número de amostras.
- $\lambda$  é o parâmetro de regularização para evitar *overfitting*<sup>1</sup>.
- $\|\mathbf{w}\|^2$  é o termo de regularização  $L2$  que penaliza grandes valores de  $\mathbf{w}$ .

Portanto, o objetivo é encontrar o vetor de pesos  $\mathbf{w}$  que minimiza a função de custo  $J(\mathbf{w})$ . Para esta questão, é fornecido um conjunto de dados de músicas com  $m = 10000$  amostras e  $n = 500$  características. Você pode aproveitar a implementação da função-objetivo disponível no arquivo `questao2.py`. Você vai ter que implementar a chamada do algoritmo de otimização. Escolha o algoritmo mais adequado para resolver o problema baseado em suas características, justifique a sua escolha e apresente os resultados da otimização.

### 3 Problema 3

Uma empresa deseja ajustar os parâmetros de uma campanha promocional para maximizar o lucro. Os parâmetros da campanha são: o desconto ( $d$ ), o tempo de duração da promoção ( $t$ ) e o orçamento em marketing ( $m$ ). O lucro da empresa ( $L(d, t, m)$ ) é igual a receita ( $R(d, t, m)$ ) menos os custos ( $C(d, t, m)$ ). A receita é dada por:

$$R(d, t, b) = V_B \cdot (1 + f_1(d) + f_2(t)) \cdot \log(1 + b) \quad (6)$$

onde:

- $V_B$  é o número de vendas sem promoção.
- $f_1(d) = -0.005d^2 + 0.2d$  é o incremento percentual nas vendas devido ao desconto.
- $f_2(t) = 0.05t$  é o incremento nas vendas proporcional ao tempo da promoção.

O custo é dado por:

$$C(d, t, b) = C_B + C_M(b) + P(d, t, m) \quad (7)$$

onde:

- $C_B$  é o custo fixo inicial.
- $C_M(m) = m$  é o custo de marketing.
- $P(d, t)$  é uma penalização não contínua:
  - Penalização de R\$5000 se  $d > 30\%$  (desconto muito agressivo).

---

<sup>1</sup> *Overfitting* é um efeito que ocorre quando um modelo aprende os dados de treinamento tão bem, incluindo ruídos e variações aleatórias presentes neles, que ele perde a capacidade de generalizar para novos dados, ou seja, dados que não foram usados durante o treinamento.

- Penalização de R\$2000 se  $t > 15$  dias.

É importante frisar que:

- O desconto não pode ser menor que 0% nem maior que 50% ( $0 \leq d \leq 50$ ).
- O tempo de duração da promoção não pode ser menor que 1 dia nem maior que 30 dias ( $1 \leq t \leq 30$ ).
- O orçamento de marketing não pode ser menor que R\$1000 nem maior que R\$50000 ( $1000 \leq b \leq 50000$ ).

Para implementar essas restrições você pode acrescentá-las às penalizações. Por exemplo, se qualquer uma dessas variáveis ultrapassar os limites, você pode adicionar somar um valor muito alto, por exemplo, 1.000.000.

Portanto, o problema geral de otimização pode ser definido como:

$$\max_{d,t,b} L(d, t, b) = R(d, t, b) - C(d, t, b) \quad (8)$$

Para este problema, você pode aproveitar a pré-implementação da função-objetivo disponível no arquivo `questao3.py`. Além de ter que implementar a chamada do algoritmo de otimização, você vai precisar implementar os cálculos das receitas, custos,  $f_1(d)$ ,  $f_2(t)$  e  $P(d, t)$ . Escolha o algoritmo mais adequado para resolver o problema, justifique a sua escolha e apresente os resultados da otimização.

## 4 Problema 4

Considere a aleta unidimensional mostrada na Fig. 1. As variáveis  $x_1$  e  $x_2$  são as temperaturas em graus Celsius dos pontos 1 e 2, respectivamente. Em regime permanente, as temperaturas  $x_1$  e  $x_2$  são tais que minimizam a seguinte função:

$$f(x_1, x_2) = 0.6382x_1^2 + 0.3191x_2^2 - 0.2809x_1x_2 - 67.906x_1 - 14.29x_2 \quad (9)$$




Figura 1: Aleta unidimensional.

Determine as temperaturas de regime permanente ( $x_1, x_2$ ) minimizando a função da equação (9). Para este problema, você terá que implementar a função-objetivo e a chamada do algoritmo de otimização. Escolha o algoritmo mais adequado para resolver o problema, justifique a sua escolha e apresente os resultados da otimização.

## 5 Observações finais

- O relatório com a discussão dos experimentos e conclusões, bem como os códigos fonte dos métodos implementados, deverão ser enviados ao professor via Moodle (trabalhos enviados por e-mail não serão considerados). Templates para a escrita do relatório estão disponíveis na página da disciplina, mas não são obrigatórios.
- Espera-se um relatório discutindo as abordagens estudadas e sua aplicação a problemas de otimização. Relatórios contendo apenas códigos e/ou figuras não serão avaliados.
- Vocês podem utilizar a linguagem de programação que preferir. Minha sugestão: Python ou MATLAB (preferencialmente Python).
- Se vocês optarem pelo Python, vocês podem utilizar a biblioteca *scipy.optimize* que já conta com as implementações dos métodos vistos em sala de aula. Também é possível utilizar a biblioteca do professor, chamada `otimo.py`.
- Se vocês optarem pelo MATLAB, vocês podem utilizar a *Optimization toolbox*.